TRABAJO FINAL · ANÁLISIS DE DATOS · ECOBICI 2023

¿Se puede predecir cuánto dura un viaje en bici pública?

Análisis exploratorio de los recorridos y usuarios de Ecobici (Buenos Aires, 2023) para clasificar la duración de cada viaje en 4 categorías.

Nancy Armua · Brian Talavera

2,62 M recorridos analizados

212.068 usuarios con al menos un viaje

364 estaciones de origen

77.380 combinaciones origen → destino

01 Análisis realizado

PASO 1
Carga y tipado
2 CSV (recorridos y usuarios). Fechas, categóricas y numéricas corregidas a mano.

PASO 2
Unión de datasets
Variable usuario_2023 para cruzar recorridos con usuarios sin perder filas.

PASO 3
EDA
Duración, estaciones, combinaciones O→D, horarios, días, meses y estación del año.

PASO 4
Medidas de asociación
Pearson, Spearman, eta², punto-biserial, Phi, Kendall y V de Cramér según el tipo. estacion_anio se descarta: V = 0,89 con mes.

PASO 5
Split y limpieza
80/20 antes de transformar; luego nulos y outliers en train y test.

PASO 6
Target y codificación
4 clases de duración, one-hot para features, ordinal para el target y z-score en lat/long.

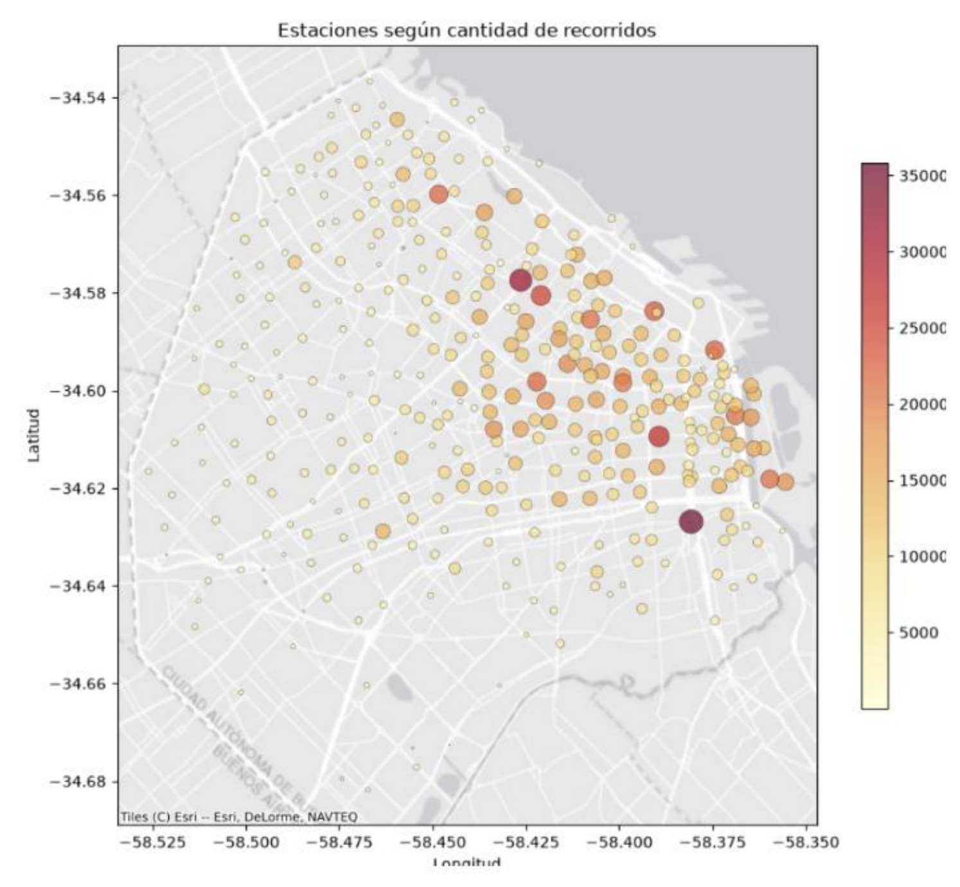

364 estaciones, concentradas en el centro y el norte de la ciudad.

02 Desafíos encontrados

24,3%
Datos de usuario incompletos
Solo esa parte de los viajes tiene edad y DNI: el archivo de usuarios trae únicamente las altas de 2023. El género viene en todos los viajes.

"1,848"
Tipos mal leídos
La duración llegó como texto con separador de miles y la edad con tipos mixtos.

72 días
Outliers extremos
Mediana de 15,5 min (sin limpiar), pero el 6% supera el límite IQR (48,8 min) y 2.023 viajes duran más de 8 h.

93%
Falsos arranques
De los viajes de menos de 2 min vuelven a la misma estación: la bici se retira y se devuelve enseguida.

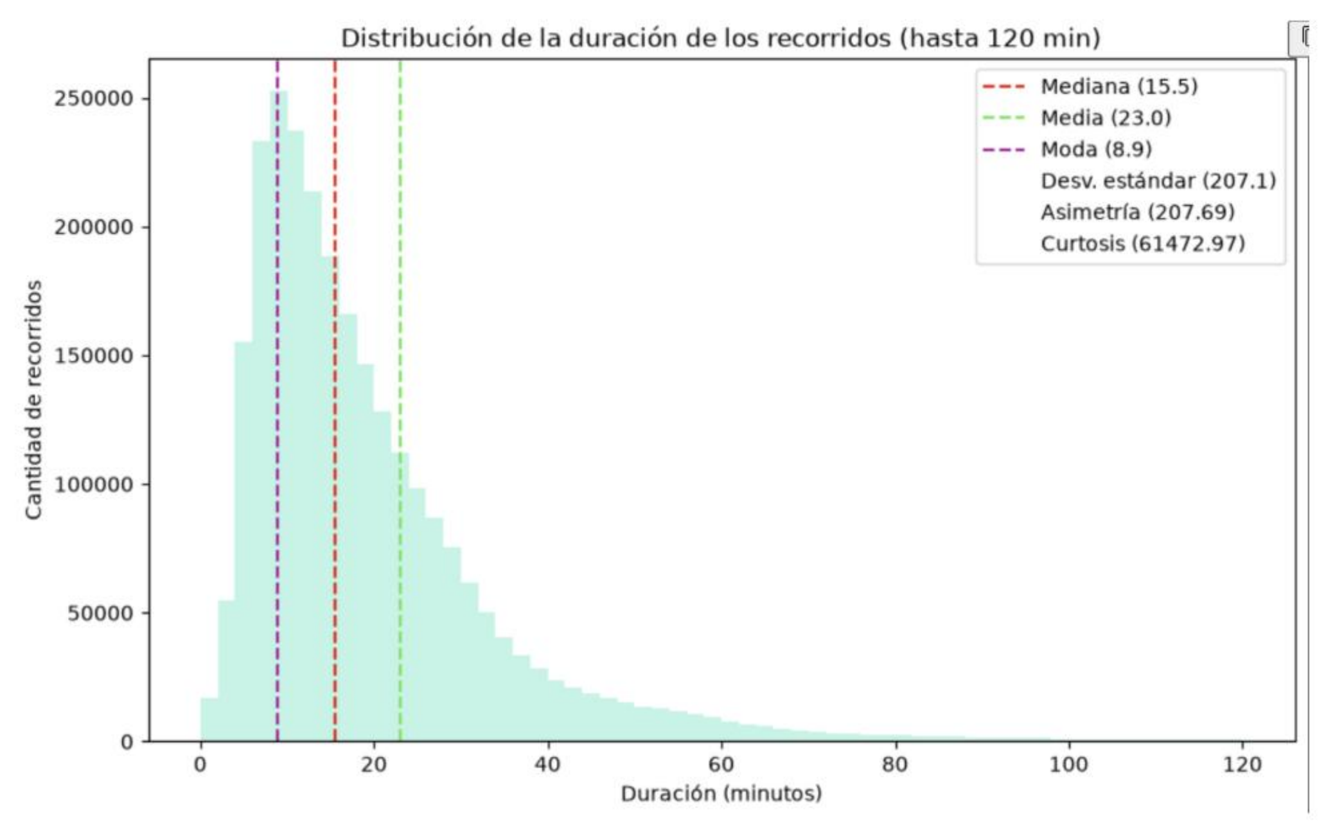

Distribución muy asimétrica: la cola larga infla la media (23 min).

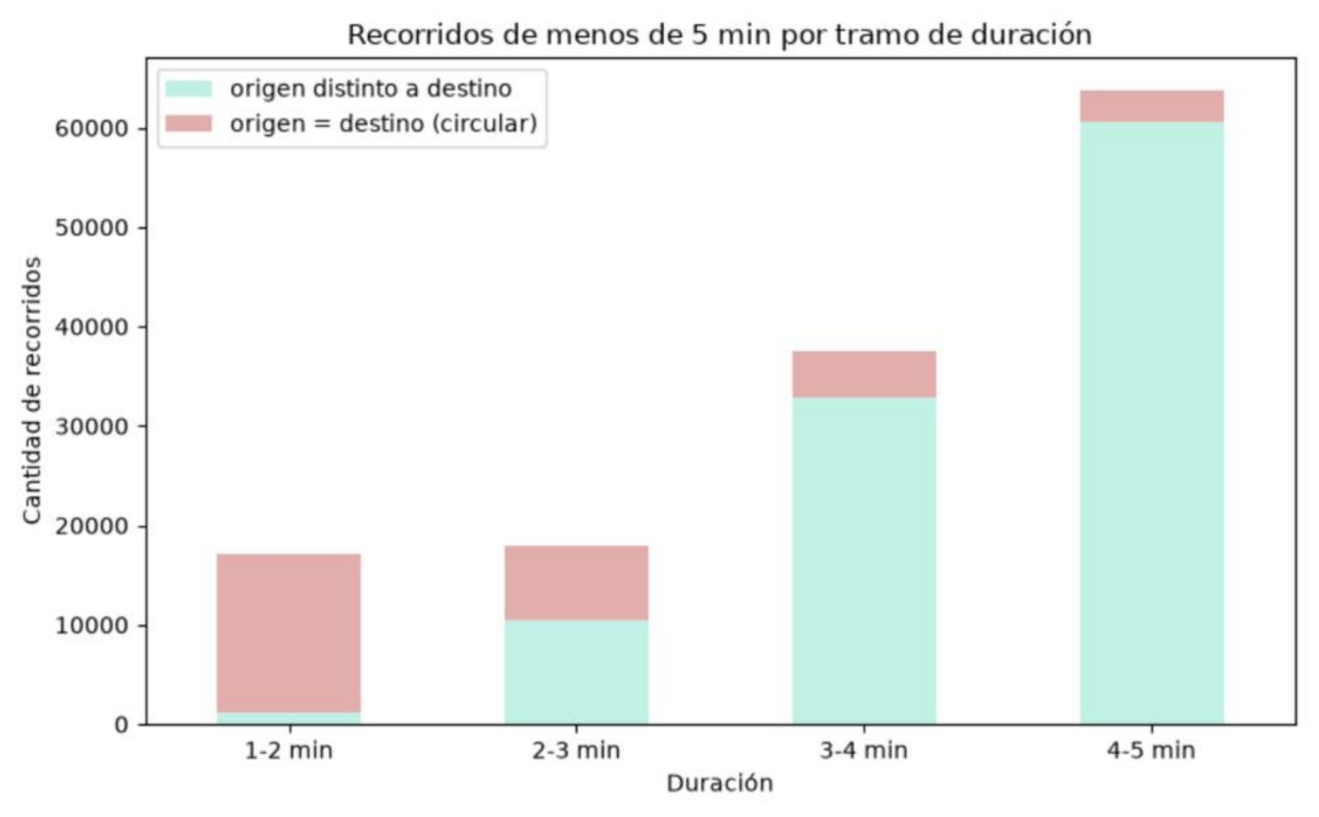

Bajo 2 min casi todo es circular; desde los 4–5 min la proporción es normal (~5%).

03 Criterios aplicados

DECISIÓN	CRITERIO	EFECTO
Split antes de todo	Umbrales, encoders y categorías del target se calculan solo con train y se aplican igual a test.	Sin fuga de información
Marca usuario_2023	En lugar de un inner join, que descartaría el 75,7% de los viajes y sesgaría la muestra.	100% de los viajes
Nulos de género	0,46% sin patrón identificable: se eliminan en lugar de imputar.	−0,46%
Outliers por regla fija	Fuera < 5 min (falsos arranques) y > 8 h (fallas o logística). Se conservan los viajes largos plausibles en vez de cortar en el IQR.	−5,3%
Target por cuartiles	Cuartiles de train redondeados a 10 / 16 / 26 min: muy corto, corto, largo, muy largo.	4 clases de ~25%
Codificación	One-hot (drop first) para género, modelo y usuario_2023; ordinal para el target; z-score en lat/long. Ids fuera y estacion_anio descartada por redundante.	9 features

2,47 M recorridos finales · 1.978.392 en train y 494.300 en test

04 Conclusiones

Asociación de cada variable con la categoría de duración

Escala 0 a 1 (V de Cramér o |Kendall τ-b| según el tipo) · solo train, sin outliers

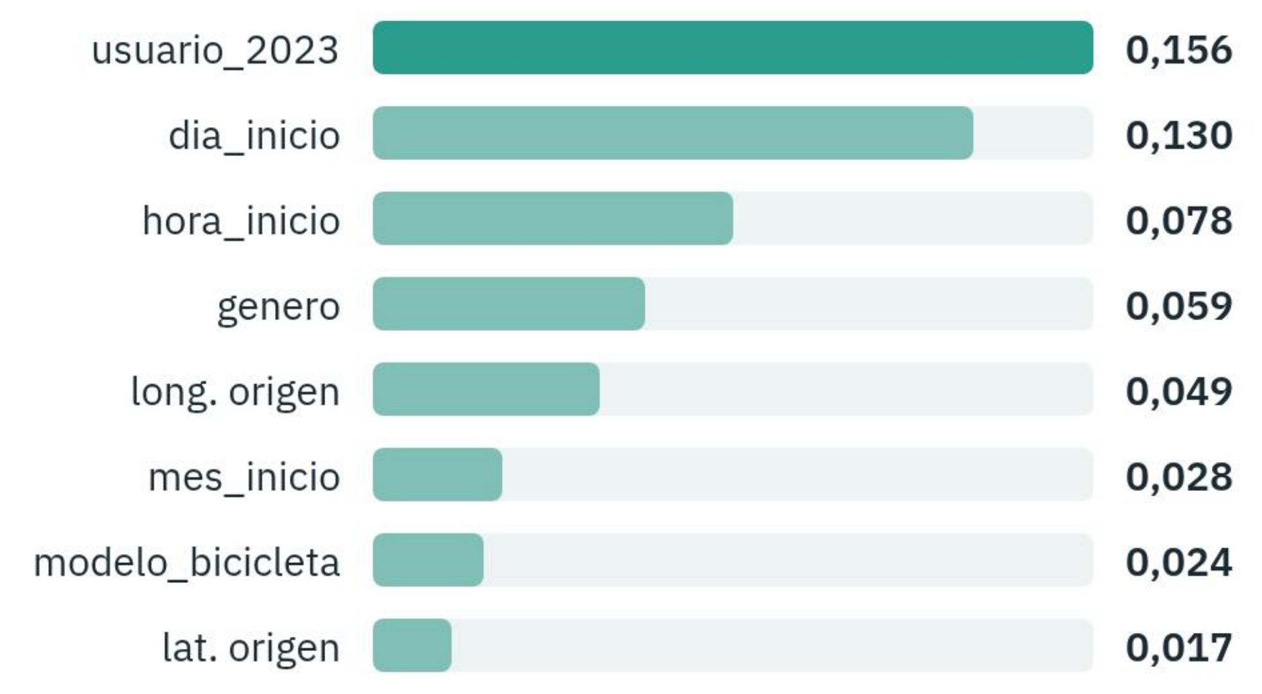

Señal débil para predecir
La variable más asociada, usuario_2023, llega a 0,156. El resto explica muy poca varianza. Con 4 clases balanceadas el azar da ~25% de accuracy: ese es el piso que el modelo debe superar.

La temporada cambia el volumen, no la duración
Primavera y verano tienen más viajes, pero la mediana se mantiene entre 15 y 16 min todo el año.

Uso ligado al trabajo
Pico a las 17 h y 86% de los viajes en días hábiles. Target final balanceado: 23% · 26% · 26% · 25%.

Fuente: datos abiertos GCBA · bicicletas públicas, recorridos y usuarios 2023